

# CRINÔMETRO

Documentação Técnica, Teórica e Metodológica

Análise de Processamento Digital de Sinais (DSP), Bioacústica Computacional,  
Aprendizado de Máquina e Métricas Fisiológicas da Estridulação de Gryllidae

**Versão do Software:** v4.3.2

**Data de Geração:** 18/09/2026 às 07:04

**Objetivo:** Servir como base formal para defesa acadêmica e redação científica, documentando exaustivamente cada cálculo, decisão algorítmica e transformação de dados implementada no programa.

# SUMÁRIO

1. Arquitetura Geral e Pipeline de Dados (Dataflow)
2. Processamento Digital de Sinais (DSP): Teoria, Cálculo e Implementação
  - 2.1. Pré-Processamento e Condicionamento do Sinal
  - 2.2. Filtragem Passa-Faixa (Bandpass Filter)
  - 2.3. Transformada de Fourier e Espectrograma (STFT)
  - 2.4. Refinamento Sub-bin Parabólico de Frequência
  - 2.5. Densidade Espectral de Potência (PSD)
3. Detecção e Segmentação Bioacústica
  - 3.1. Extração de Envelope Temporal
  - 3.2. Algoritmo de Segmentação e Thresholding
  - 3.3. Agrupamento Hierárquico de Chirpeiros
  - 3.4. Tratamento de Ruídos e Falsos Positivos
4. Cálculo de Métricas Biométricas e Modelagem Fisiológica
  - 4.1. Métricas Temporais de Estridulação
  - 4.2. Diagnóstico Rítmico (Aceleração vs. Desaceleração)
  - 4.3. Correlação Termo-Acústica (Lei de Dolbear)
5. Módulo de IA e Aprendizado Ativo
  - 5.1. Vetor de Características (Feature Engineering)
  - 5.2. Separação Não-Supervisionada (GMM Bimodal)
  - 5.3. Classificador Supervisionado (HistGradientBoosting)
  - 5.4. Mineração de Negativos Difíceis (Hard Negative Mining)
  - 5.5. Filtro de Coerência Rítmica
  - 5.6. Ciclo de Feedback do Aprendizado Ativo
6. Glossário Metodológico para Defesa Acadêmica

# 1. ARQUITETURA GERAL E PIPELINE DE DADOS (DATAFLOW)

---

## 1.1. Ciclo de Vida do Sinal de Áudio

O Crinômetro implementa um pipeline sequencial de processamento que transforma uma gravação bruta em formato WAV em um conjunto estruturado de métricas bioacústicas e visualizações interativas. O ciclo de vida completo é:






Figura 1: Diagrama de fluxo do pipeline completo de processamento do Crinômetro.

## 1.2. Organização Modular e Desacoplamento

A arquitetura do Crinômetro separa rigorosamente a camada de interface gráfica (GUI) da camada de processamento matemático. Esta decisão atende a três requisitos fundamentais: (a) permitir que operações de DSP pesadas executem em threads secundárias sem congelar a interface; (b) facilitar testes unitários do core sem dependência do Qt; e (c) possibilitar reutilização do motor analítico em contextos não-interativos (scripts de lote, pipelines acadêmicos).

| Módulo                    | Arquivo                   | Responsabilidade                                                                                        |
|---------------------------|---------------------------|---------------------------------------------------------------------------------------------------------|
| CricketAnalyzer           | core/analyzer.py          | Pipeline DSP completo: filtragem, espectrograma, detecção de pulsos, agrupamento de chirreios, métricas |
| PulseLearner              | core/learner.py           | ML Active Learning: extração de features, GMM, classificação supervisionada, poda contrastiva           |
| HighPerfLineEngine        | core/engines.py           | Renderização adaptativa LOD de formas de onda com decimação min-max                                     |
| HighPerfSpectrogramEngine | core/engines.py           | Renderização adaptativa de espectrogramas com cache de tiles e stride slicing                           |
| HighPerfFreqEngine        | core/engines.py           | Renderização adaptativa de scatter plots de frequência dominante                                        |
| GenericWorker             | core/worker.py            | Wrapper QThread com cancelamento cooperativo e sinalização typed                                        |
| MainWindow                | ui/main_window.py         | Orquestrador central: UI, estado, navegação, edição interativa, playback                                |
| PlotPanel                 | ui/panels.py              | Card de gráfico Matplotlib com tema, drag-drop, toolbar e tooltips                                      |
| report_generator          | utils/report_generator.py | Geração de relatórios PDF acadêmicos via ReportLab                                                      |

O desacoplamento é mediado pelo padrão de **worker assíncrono**: a `MainWindow` instancia um `GenericWorker(QThread)` que executa `CricketAnalyzer.analyze()` em uma thread secundária. Ao concluir, o resultado é emitido via sinal Qt (`finished_signal`) e recebido pelo slot da `MainWindow` na thread principal, que então atualiza a GUI. Este mecanismo garante que operações de FFT, Hilbert e classificação ML nunca bloqueiem o event loop do Qt.

## 2. PROCESSAMENTO DIGITAL DE SINAIS (DSP)

### 2.1. Pré-Processamento e Condicionamento do Sinal

Antes da análise bioacústica propriamente dita, o sinal bruto passa por três etapas de condicionamento que removem artefatos comuns em gravações de campo:

#### *Etapa 1: Leitura e Normalização*

O arquivo WAV é lido via `scipy.io.wavfile.read()`. Se o arquivo for estéreo (2 canais), os canais são colapsados para mono pela média aritmética: `data = raw.mean(axis=1)`. A amplitude é normalizada ao intervalo  $[-1.0, +1.0]$  dividindo pelo valor máximo absoluto do tipo de dado (32768 para int16, 2147483648 para int32). O resultado é convertido para float32 para reduzir em 50% o consumo de memória em relação a float64.

#### *Etapa 2: Remoção do Offset DC*

A média aritmética do sinal é subtraída de todas as amostras: `data = data - np.mean(data)`. Isto elimina qualquer componente de corrente contínua (DC offset) que possa estar presente devido a imperfeições no circuito de gravação ou calibração do microfone. Um offset DC não removido introduziria um pico espúrio em 0 Hz no espectro, distorcendo a detecção de frequência portadora.

#### *Etapa 3: Filtro Passa-Altas Anti-Vento (50 Hz)*

Um filtro Butterworth IIR de 2ª ordem com frequência de corte em 50 Hz é aplicado para atenuar ruídos de vento, vibrações mecânicas do suporte do microfone e interferência eletromagnética de rede elétrica (hum de 50/60 Hz). A topologia Butterworth foi escolhida por sua resposta em magnitude maximamente plana na banda passante, evitando ripple que poderia distorcer a envoltória temporal dos pulsos.

A implementação utiliza a forma SOS (Second-Order Sections) ao invés da forma de função de transferência (b, a) para garantir estabilidade numérica. A função de transferência de um filtro Butterworth passa-altas de 2ª ordem é:

$$H(s) = s^2 / (s^2 + \sqrt{2} \cdot \omega_c \cdot s + \omega_c^2) \text{ onde } \omega_c = 2\pi \times 50 \text{ Hz}$$

### 2.2. Filtragem Passa-Faixa (Bandpass Filter)

A etapa central de isolamento do sinal de estridulação utiliza um filtro Butterworth IIR passa-faixa de **4ª ordem** (cascata de 2 seções de 2ª ordem) com frequências de corte configuráveis. Os valores padrão —  $f_{\text{low}} = 3200 \text{ Hz}$  e  $f_{\text{high}} = 6000 \text{ Hz}$  — foram calibrados empiricamente para capturar a faixa de estridulação da maioria das espécies de Gryllidae comuns em gravações de campo no Brasil (gêneros *Gryllus*, *Anurogryllus*, *Oecanthus*).

#### *Justificativa da Topologia Butterworth*

A resposta em magnitude do filtro Butterworth de ordem N satisfaz:

$$|H(j\omega)|^2 = 1 / [1 + (\omega/\omega_c)^{(2N)}]$$

Três propriedades tornam esta topologia ideal para bioacústica de insetos: (1) **Resposta maximamente plana** na banda passante — não introduz ripple que distorceria a envoltória temporal dos pulsos. Filtros Chebyshev tipo I, por exemplo, apresentam oscilações na banda passante que poderiam gerar falsos

picos no envelope. (2) **Atenuação monotônica** na banda de rejeição — garante supressão progressiva de frequências fora da faixa de interesse sem side-lobes. (3) **Fase suavemente variável** — embora não seja linear, a fase do Butterworth é mais suave que a do Chebyshev, preservando melhor a forma temporal dos pulsos de estridulação.

A **4ª ordem** (atenuação de 80 dB/década = 24 dB/oitava por polo) fornece uma rejeição suficiente para separar o canto do grilo focal de fontes de banda larga (tráfego, vento, outros artrópodes) sem o custo computacional de ordens superiores. Ordens acima de 6 tendem a causar instabilidade numérica na forma (b, a), embora a implementação SOS mitigue este risco.

### Implementação

```
sos = scipy.signal.butter(4, [f_low/(sr/2), f_high/(sr/2)], btype='band',
output='sos')
data_filtered = scipy.signal.sosfilt(sos, data).astype(np.float32)
```

A normalização das frequências de corte pelo Nyquist ( $sr/2$ ) é necessária porque a função `butter()` espera frequências normalizadas no intervalo (0, 1). Valores fora de (0.001, 0.999) são clampeados para evitar instabilidade.

## 2.3. Transformada de Fourier de Curto Tempo (STFT) e Espectrograma

O espectrograma do Crinômetro é calculado via STFT usando a função `scipy.signal.spectrogram()` com os seguintes parâmetros:

| Parâmetro             | Valor Padrão                | Significado Físico                                           |
|-----------------------|-----------------------------|--------------------------------------------------------------|
| <code>nperseg</code>  | 1024 amostras               | Tamanho da janela de análise ( $\approx 23.2$ ms a 44.1 kHz) |
| <code>window</code>   | Hann (cosseno elevado)      | Função de janelamento para redução de vazamento espectral    |
| <code>noverlap</code> | 768 amostras (75%)          | Sobreposição entre janelas consecutivas                      |
| <code>hop_size</code> | 256 amostras (= 1024 - 768) | Deslocamento temporal entre quadros ( $\approx 5.8$ ms)      |
| <code>scaling</code>  | 'spectrum'                  | Retorna potência por bin de frequência (não por Hz)          |

### Resoluções Resultantes

O Princípio da Incerteza de Heisenberg-Gabor estabelece que a resolução temporal ( $\Delta t$ ) e a resolução espectral ( $\Delta f$ ) de qualquer análise tempo-frequência são mutuamente exclusivas:

$$\Delta t \times \Delta f \geq 1 / (4\pi)$$

Para os parâmetros escolhidos ( $sr = 44100$  Hz,  $nperseg = 1024$ ):

- **Resolução em frequência:**  $\Delta f = sr / nperseg = 44100 / 1024 \approx 43.07$  Hz
- **Resolução temporal:**  $\Delta t = hop\_size / sr = 256 / 44100 \approx 5.8$  ms

Esta parametrização privilegia a **resolução temporal** em detrimento da espectral. A escolha é fundamentada na natureza do sinal de estridulação: cada pulso individual de um grilo dura tipicamente entre 3 e 30 ms, exigindo resolução temporal sub-milissegundos para segmentação precisa. A resolução espectral de  $\sim 43$  Hz é suficiente para distinguir a frequência portadora (tipicamente entre 3 e 8 kHz) e seus harmônicos mais proeminentes.

## Conversão para Decibéis

A matriz de potência  $S_{xx}$  é convertida para escala logarítmica:

$$S_{dB}(f, t) = 10 \cdot \log_{10}(S_{xx}(f, t) + 10^{-10})$$

O epsilon aditivo ( $10^{-10}$ , equivalente a -100 dB) previne o logaritmo de zero em regiões de silêncio absoluto. A matriz resultante é convertida para float32 para economia de memória.

## 2.4. Refinamento Sub-bin Parabólico de Frequência

A resolução espectral do espectrograma (~43 Hz) é insuficiente para rastreamento preciso da frequência portadora do grilo, cuja variação natural pode ser de apenas  $\pm 10$ -20 Hz. Para superar esta limitação, o Crinômetro aplica **interpolação parabólica sub-bin** a cada coluna temporal do espectrograma.

Para cada instante  $t$ , identifica-se o bin de frequência  $k$  com maior potência. Usando os valores de potência logarítmica dos bins adjacentes ( $k-1$ ,  $k$ ,  $k+1$ ), calcula-se o offset fracionário  $p$  do pico verdadeiro:

$$p = 0.5 \times (\alpha - \gamma) / (\alpha - 2\beta + \gamma)$$

$$\text{onde } \alpha = S_{dB}[k-1], \beta = S_{dB}[k], \gamma = S_{dB}[k+1]$$

A frequência dominante refinada é então:

$$f_{\text{peak}}(t) = f[k] + p \times \Delta f$$

Este método reduz o erro de estimação de frequência de  $\pm \Delta f/2$  ( $\approx 21.5$  Hz) para aproximadamente  $\pm \Delta f/10$  ( $\approx 4.3$  Hz), oferecendo precisão sub-bin sem o custo computacional de zero-padding ou janelas maiores.

## 3. DETECÇÃO E SEGMENTAÇÃO BIOACÚSTICA

### 3.1. Extração de Envelope Temporal

O envelope de amplitude é a curva que delineia os picos instantâneos do sinal filtrado, eliminando as oscilações rápidas da frequência portadora e preservando apenas a modulação de amplitude (AM) que define a estrutura temporal dos pulsos. O Crinômetro utiliza a **Transformada de Hilbert** para esta finalidade.

#### Fundamento Matemático

Dado um sinal real  $x(t)$ , a Transformada de Hilbert produz o sinal analítico:

$$x_a(t) = x(t) + j \cdot H\{x(t)\}$$

onde  $H\{\cdot\}$  é o operador de Hilbert (rotação de fase de  $-90^\circ$  para frequências positivas e  $+90^\circ$  para negativas). O envelope instantâneo é o módulo do sinal analítico:

$$A(t) = |x_a(t)| = \sqrt{[x(t)]^2 + [H\{x(t)\}]^2}$$

#### Implementação e Suavização

```
analytic = scipy.signal.hilbert(data_filtered)
envelope = np.abs(analytic).astype(np.float32)
```

O envelope bruto apresenta ripple residual da portadora. Para eliminar estas flutuações, aplica-se uma **suavização por janela de Hanning** via convolução:

```
win = np.hanning(smooth_samples)
win /= win.sum()
envelope_smooth = np.convolve(envelope, win, mode='same')
```

O tamanho da janela de suavização (padrão: 2 ms, configurável pelo pesquisador) controla o trade-off entre resolução temporal e supressão de ripple. Janelas maiores produzem envelopes mais suaves mas podem fundir pulsos adjacentes muito próximos; janelas menores preservam detalhes mas podem gerar detecções espúrias.

#### Normalização Robusta

O envelope é normalizado pelo percentil 99.85 da distribuição de amplitude (ao invés do máximo absoluto). Esta abordagem é robusta a cliques, estalos e artefatos transientes que poderiam comprimir toda a faixa dinâmica se o máximo absoluto fosse utilizado. A constante 99.85 foi calibrada empiricamente para rejeitar os 0.15% mais extremos das amostras sem afetar os pulsos legítimos de estridulação.

### 3.2. Algoritmo de Detecção de Pulsos e Thresholding

A detecção de pulsos opera sobre o envelope suavizado e normalizado. O processo envolve três fases: (1) estimação do limiar adaptativo, (2) detecção de picos, e (3) validação morfológica.

#### Fase 1: Limiar Adaptativo

O limiar de detecção é calculado adaptativamente a partir da distribuição estatística do envelope:

$$\text{threshold} = \max(\text{amp\_min} \times \text{noise\_floor}, P_{25} \times 2.5)$$

onde **amp\_min** é o limiar mínimo configurável (padrão: 0.08), **noise\_floor** é a mediana do envelope nas regiões de silêncio, e **P<sub>25</sub>** é o 25º percentil da distribuição do envelope. O fator multiplicativo de 2.5 foi determinado empiricamente para maximizar a taxa de detecção verdadeira (recall) mantendo a taxa de falsos positivos abaixo de 5% em gravações com SNR  $\geq 10$  dB.

### **Fase 2: Detecção de Picos**

A detecção utiliza `scipy.signal.find_peaks()` com os seguintes critérios:

- **height**: threshold calculado na Fase 1
- **prominence**: proeminência mínima configurável (garante que o pico se destaque significativamente de seus vizinhos)
- **width**: largura do pico a 50% da altura entre `width_min` e `width_max` (em amostras), equivalente à duração do pulso entre `dur_min` e `dur_max` (em ms)
- **distance**: distância mínima entre picos consecutivos ( $= \text{gap\_min} \times \text{sr}$ , prevenindo dupla detecção)

### **Fase 3: Validação Morfológica**

Cada pulso candidato é submetido a validação de duração:

- Duração calculada:  $d = \text{largura do pico a 50\% da altura (FWHM) via } \text{peak\_widths}()$
- Critério:  $\text{dur\_min (3 ms)} \leq d \leq \text{dur\_max (50 ms)}$
- Pulsos fora deste intervalo são rejeitados como artefatos (muito curtos = cliques; muito longos = sobreposição de múltiplos pulsos)

## **3.3. Identificação da Frequência Portadora e Filtragem Espectral**

Após a detecção de pulsos candidatos, o sistema identifica a **frequência portadora modal** — a frequência de estridulação dominante que caracteriza o indivíduo focal.

**Algoritmo:** Para cada pulso validado, extrai-se a frequência dominante do espectrograma no instante do pico (usando o refinamento sub-bin parabólico da Seção 2.4). Constrói-se um histograma ponderado dessas frequências com largura de bin de 50 Hz, e a moda do histograma é designada como a frequência portadora  $f_{\text{carrier}}$ .

Pulsos cuja frequência dominante difere da portadora em mais de  $\pm \text{freq\_tolerance}$  (padrão: 300 Hz) são rejeitados como provenientes de outras fontes acústicas (outros grilos, cigarras, ruído ambiental). Esta é a **Filtragem de Rejeição de Banda Estreita** introduzida na v4.3.0.

## **3.4. Agrupamento Hierárquico em Chilreios (Chirps)**

Os pulsos validados e filtrados espectralmente são agrupados em **chilreios** (chirps) — sequências rítmicas de pulsos produzidas por um único ciclo de fechamento tegminal. O agrupamento segue um algoritmo sequencial com múltiplas camadas de validação:

**Camada 1 — Agrupamento Temporal:** Pulsos consecutivos são agrupados no mesmo chilreio se o intervalo inter-pulso (IPI) estiver dentro do intervalo  $[\text{gap\_min}, \text{gap\_max}]$  (padrão: [20 ms, 40 ms]). Um IPI menor que `gap_min` sugere colisão de dois pulsos sobrepostos; um IPI maior que `gap_max` indica o fim do chilreio.

**Camada 2 — Coerência de Amplitude:** Dentro de cada chilreio candidato, a amplitude dos pulsos é verificada: a razão entre o pulso mais fraco e a mediana não deve exceder um fator de 1.65×. Isto rejeita

intrusões de pulsos distantes (coro de fundo) que coincidem temporalmente mas apresentam amplitude discrepante.

**Camada 3 — Detecção de Colisão:** Se dois pulsos estão separados por menos de  $0.8 \times \text{gap\_min}$ , é provável que sejam pulsos sobrepostos de dois indivíduos diferentes. O sistema retém o pulso de maior amplitude e descarta o mais fraco.

**Camada 4 — Portão ICI (Inter-Chirp Interval Gate):** Após o agrupamento inicial, aplica-se um filtro de período refratário fisiológico. Para cada par de chilreios consecutivos, se o intervalo inter-chilreio (ICI) for inferior a 70% da mediana dos ICIs ( $\text{ICI}_{\text{gate}} = 0.70 \times \text{ICI}_{\text{mediana}}$ ), os dois chilreios são fundidos em um único (o intervalo era curto demais para ser uma pausa fisiológica real).

**Camada 5 — Validação de Contagem Mínima:** Chilreios com menos de  $\text{min\_p}$  pulsos (padrão: 3) são descartados, pois não constituem uma sequência rítmica suficiente para classificação bioacústica confiável.

### 3.5. Tratamento de Ruídos e Falsos Positivos

O sistema emprega múltiplas estratégias hierárquicas para discriminar sinal de ruído:

- **Filtragem passa-faixa:** Remove ruído fora da banda de estridulação
- **Threshold adaptativo:** Se ajusta ao nível de ruído específico da gravação
- **Validação morfológica:** Rejeita pulsos com duração ou largura fora do esperado
- **Tolerância espectral:** Rejeita pulsos com frequência fora da portadora  $\pm 300$  Hz
- **Coerência de amplitude:** Remove intrusos com amplitude incompatível
- **ICI Gate:** Rejeita detecções no período refratário fisiológico
- **Classificador ML (opcional):** Discriminação supervisionada baseada em 20 features acústicas

**Diferenciação de pausa fisiológica vs. ruído transitório:** Uma pausa fisiológica genuína (o grilo interrompeu temporariamente a estridulação) é caracterizada por: (a) ICI significativamente maior que a mediana ( $> 3\times$ ), (b) ausência de pulsos espúrios durante a pausa, e (c) retomada da cadência com IPI consistente. O sistema identifica estas pausas e as exclui dos cálculos de taxa e cadência para evitar distorção das métricas.

## 4. CÁLCULO DE MÉTRICAS BIOMÉTRICAS E MODELAGEM FISIOLÓGICA

### 4.1. Métricas Temporais de Estridulação

As métricas bioacústicas calculadas pelo Crinômetro são formalmente definidas a seguir. Todas as equações são aplicadas sobre os chilreios validados pelo pipeline completo.

| Métrica                    | Símbolo               | Fórmula                                                                    | Unidade    |
|----------------------------|-----------------------|----------------------------------------------------------------------------|------------|
| Total de Chilreios         | N_c                   | Contagem de chirps validados                                               | —          |
| Total de Pulsos            | N_p                   | $\sum  \text{chirp}_i $ para todos os chirps                               | —          |
| Taxa de Chilreios          | R_c                   | $N_c / T_{\text{total}}$                                                   | chirps/s   |
| Cadência                   | R_min                 | $R_c \times 60$                                                            | chirps/min |
| ICI Médio                  | $\mu_{\text{ICI}}$    | $(1/n) \sum (\text{onset}[i+1] - \text{offset}[i])$                        | ms         |
| ICI Desvio Padrão          | $\sigma_{\text{ICI}}$ | $\text{std}(\text{ICIs})$                                                  | ms         |
| IPI Médio                  | $\mu_{\text{IPI}}$    | $(1/m) \sum (\text{onset}[j+1] - \text{offset}[j])$ intra-chirp            | ms         |
| IPI Desvio Padrão          | $\sigma_{\text{IPI}}$ | $\text{std}(\text{IPIs})$                                                  | ms         |
| Duração Média do Pulso     | $\mu_{\text{d}_p}$    | $(1/N_p) \sum (\text{offset}[k] - \text{onset}[k])$                        | ms         |
| Duração Média do Chilreio  | $\mu_{\text{d}_c}$    | $(1/N_c) \sum (\text{offset}_{\text{last}} - \text{onset}_{\text{first}})$ | ms         |
| Pulsos por Chilreio (Moda) | Mo_ppc                | $\text{mode}(\{ \text{chirp}_i \})$                                        | —          |
| Frequência Portadora       | f_carrier             | moda do histograma espectral (50 Hz bins)                                  | Hz         |

O **Intervalo Inter-Chilreio (ICI)** é medido do offset do último pulso de um chilreio ao onset do primeiro pulso do chilreio seguinte. O **Intervalo Inter-Pulso (IPI)** é medido analogamente dentro de um mesmo chilreio. Esta definição (offset-to-onset) ao invés de (onset-to-onset) é mais apropriada bioacusticamente pois mede o período de silêncio real entre eventos, e não o período do ciclo que inclui a duração do evento anterior.

### 4.2. Diagnóstico Rítmico (Aceleração vs. Desaceleração)

O diagnóstico rítmico avalia se o grilo está acelerando, desacelerando ou mantendo cadência estável ao longo da gravação. O modelo empregado é uma **regressão linear simples** dos ICIs ao longo do tempo:

$$\text{ICI}(t) = \beta_0 + \beta_1 \cdot t + \epsilon$$

onde  $\beta_1$  (slope) é a taxa de variação do ICI em ms/s. O ajuste é realizado via `numpy.polyfit(timestamps, icis_ms, deg=1)`.

**Critérios de Diagnóstico:**

- **Aceleração:**  $\beta_1 < -0.15$  ms/s E p-valor  $< 0.05$   
(ICIs ficando menores → chirps mais frequentes → acelerando)
- **Desaceleração:**  $\beta_1 > +0.15$  ms/s E p-valor  $< 0.05$

(ICIs ficando maiores → chirps menos frequentes → desacelerando)

• **Estável:**  $|\beta| \leq 0.15 \text{ ms/s}$  OU p-valor  $\geq 0.05$

(Sem tendência significativa)

A significância estatística é testada via **coeficiente de correlação de Pearson** convertido em estatística t de Student:

$$t = r \times \sqrt{[(n-2) / (1 - r^2)]} \rightarrow p = 2 \times [1 - \text{CDF}_t(|t|, df=n-2)]$$

**Filtragem de pausas fisiológicas:** ICIs maiores que 3× a mediana são excluídos da regressão, pois representam interrupções do comportamento de estridulação (o grilo parou de cantar brevemente) e não variações rítmicas genuínas.

### 4.3. Correlação Termo-Acústica (Lei de Dolbear)

A Lei de Dolbear (1897) descreve uma relação empírica aproximadamente linear entre a taxa de estridulação de grilos e a temperatura ambiente. A formulação implementada no Crinômetro é baseada na versão simplificada para grilo-de-campo (*Gryllus*):

$$T(^{\circ}\text{C}) = (R_{\min} - 40) / 4 + 10$$

onde  $R_{\min}$  é a cadência de chilreios por minuto. Esta fórmula é derivada da Lei de Dolbear original para *Oecanthus fultoni* ( $T^{\circ}\text{F} = 40 + n/4$ , onde  $n$  = número de chirps em 13 segundos), adaptada e convertida para Celsius.

**Limitações importantes:** A estimativa de temperatura é apresentada como valor informativo e indicativo, não como medição precisa. A relação é espécie-específica — grilos de espécies diferentes (e.g., *Gryllus* vs. *Oecanthus*) têm coeficientes distintos. Além disso, fatores como estresse, competição intraespecífica e estado nutricional podem modular a taxa independentemente da temperatura.

## 5. MÓDULO DE IA E APRENDIZADO ATIVO

O módulo de inteligência artificial do Crinômetro (PulseLearner) implementa um sistema híbrido de classificação que combina (a) clustering não-supervisionado via GMM bimodal, (b) classificação supervisionada via gradient boosting, e (c) aprendizado ativo onde o pesquisador refina progressivamente o modelo corrigindo detecções individuais.

### 5.1. Vetor de Características (Feature Engineering)

Para cada pulso candidato, o sistema extrai um **vetor de 20 características** bioacústicas calculadas em uma janela de  $\pm 30$  ms centrada no pico do envelope. Estas características foram selecionadas para serem **invariantes a ganho** (normalizadas por amplitude local) e **fisicamente interpretáveis**:

| #  | Feature              | Fórmula / Método                                              | Significado Bioacústico                              |
|----|----------------------|---------------------------------------------------------------|------------------------------------------------------|
| 1  | peak_amp_rel         | $A_{\text{peak}} / \text{mediana}(A_{\text{local}})$          | Amplitude relativa: distingue focal de coro distante |
| 2  | peak_width_s         | FWHM a 50% da altura                                          | Duração do pulso: espécie-específica                 |
| 3  | peak_width_75_s      | Largura a 75% da altura                                       | Forma do pico: pulsos focais são mais estreitos      |
| 4  | local_snr_db         | $20 \cdot \log_{10}(A_{\text{peak}} / \sigma_{\text{local}})$ | Razão sinal-ruído local                              |
| 5  | energy_rel           | $E_{\text{janela}} / A_{\text{peak}}^2$                       | Energia normalizada do pulso                         |
| 6  | std_amp_rel          | $\sigma_{\text{local}} / A_{\text{peak}}$                     | Variabilidade de amplitude local                     |
| 7  | prominence_ratio     | $(A_{\text{peak}} - A_{\text{vale}}) / A_{\text{peak}}$       | Proeminência relativa do pico                        |
| 8  | peak_sharpness_rel   | $d^2\text{env}/dt^2$ no pico (normalizado)                    | Agudeza do pico (2ª derivada)                        |
| 9  | crest_factor         | $A_{\text{peak}} / \text{RMS}_{\text{local}}$                 | Fator de crista: impulsividade do sinal              |
| 10 | skewness_local       | $(\mu_{\text{esq}} - \mu_{\text{dir}}) / A_{\text{peak}}$     | Assimetria temporal do envelope                      |
| 11 | local_density_rel    | $E_{\pm 10\text{ms}} / E_{\pm 30\text{ms}}$                   | Concentração de energia temporal                     |
| 12 | autocorr_1ms         | $r(\tau=1\text{ms})$ normalizada                              | Periodicidade a curto prazo                          |
| 13 | band_energy_ratio    | $E_{\pm 10\text{ms}} / E_{\pm 30\text{ms}}$                   | Foco energético vs contexto                          |
| 14 | rise_slope_rel       | $\Delta\text{env}/\Delta t$ (vale→pico)                       | Velocidade de ataque do pulso                        |
| 15 | spectral_centroid    | $\Sigma(f \cdot  X ) / \Sigma X $                             | Centro de massa espectral (Hz)                       |
| 16 | spectral_rolloff_85  | f tal que $\text{CDF}( X ^2)=0.85$                            | Decaimento espectral a 85%                           |
| 17 | attack_time_10_90_ms | $t(90\%) - t(10\%)$ interpolado                               | Tempo de subida 10-90% (ms)                          |
| 18 | local_hnr_db         | $E_{\text{harmônica}} / E_{\text{ruído}} (\pm 150\text{Hz})$  | Razão harmônico-ruído local                          |
| 19 | multiscale_energy    | $E_{\pm 10\text{ms}} / E_{\pm 40\text{ms}}$                   | Razão energia multiescala                            |
| 20 | prior_p_focal        | $P(\text{focal} \mid \text{GMM})$                             | Prior não-supervisionado do GMM                      |

### 5.2. Separação Não-Supervisionada (GMM Bimodal)

O módulo GMM (Gaussian Mixture Model) modela a distribuição das features de pulso como uma mistura de **duas gaussianas** representando dois clusters:

- **Cluster Focal:** Pulsos do grilo mais próximo (alta amplitude, centroide espectral consistente, alto HNR)
- **Cluster Coro/Ruído:** Pulsos distantes, ecos, ruído ambiental (baixa amplitude, centroide disperso, baixo HNR)

O GMM é ajustado em um espaço bidimensional de [log(amplitude), centroide\_espectral] padronizado (Z-score). A designação focal/coro é feita automaticamente: o cluster com maior média de amplitude + 0.5 × centroide é marcado como focal.

$$P(\text{focal} \mid x) = \pi_{\text{focal}} \cdot N(x \mid \mu_{\text{focal}}, \Sigma_{\text{focal}}) / \sum_k \pi_k \cdot N(x \mid \mu_k, \Sigma_k)$$

O `GaussianMixture` do `scikit-learn` é instanciado com `n_components=2`, `covariance_type='full'`, `n_init=5`. O uso de covariância 'full' permite clusters elipsoidais de orientação arbitrária, capturando correlações entre amplitude e frequência.

### 5.3. Classificador Supervisionado (HistGradientBoosting)

Quando o pesquisador fornece correções manuais, o sistema treina um classificador supervisionado que substitui (ou complementa) a classificação GMM.

#### *Classificador Primário: HistGradientBoostingClassifier*

- **max\_iter:** 200 iterações de boosting
- **max\_depth:** 3-4 (árvores rasas para evitar overfitting com poucos exemplos)
- **learning\_rate:** 0.1
- **l2\_regularization:** 2.0 (quando < 30 amostras) — regularização forte
- **class\_weight:** 'balanced' — compensa desbalanceamento entre classes
- **min\_samples\_leaf:** 5 — evita folhas com pouquíssimas amostras

O **HistGradientBoosting** foi escolhido por duas vantagens: (1) construção de histogramas de features é  $O(n)$  em vez de  $O(n \cdot \log n)$  como GBDT clássico, permitindo treinamento rápido durante a interação do pesquisador; (2) suporta nativamente valores faltantes (NaN) sem necessidade de imputação.

#### *Classificador de Fallback: RandomForestClassifier*

Se o HistGradientBoosting não estiver disponível (versões antigas do sklearn), o sistema utiliza um Random Forest com 500 estimadores, `max_depth=10`, `n_jobs=-1` (paralelismo total).

#### *Score Híbrido*

A decisão final combina a probabilidade do classificador supervisionado com o prior do GMM:

$$\text{Score} = 0.65 \times P(\text{válido} \mid \text{classificador}) + 0.35 \times P(\text{focal} \mid \text{GMM})$$

Um pulso é aceito se  $\text{Score} \geq \text{focal\_sensitivity}$  (padrão: 0.60). O peso maior no classificador (65%) reflete a maior confiabilidade das labels humanas em relação ao clustering não-supervisionado.

### 5.4. Mineração de Negativos Difíceis (Hard Negative Mining)

Quando o pesquisador remove manualmente pulsos falsos positivos (clikando em marcadores espúrios), o sistema analisa os vetores de features desses negativos explícitos e **induz regras de poda**

**contrastivas.**

**Algoritmo:** Para cada uma das 20 features, compara-se a distribuição dos positivos validados vs. negativos explícitos. Se uma feature  $f_i$  separa perfeitamente os dois grupos (i.e., nenhum overlap), uma regra é criada:

Se  $f_i < \text{threshold\_com\_margem\_30\%} \rightarrow \text{Rejeitar pulso}$

A margem de segurança de 30% previne rejeição de positivos borderline. Estas regras são aplicadas **antes** do classificador ML, funcionando como um filtro rápido  $O(1)$  por pulso.

## 5.5. Filtro de Coerência Rítmica $O(N)$

Após o agrupamento em chilreios, aplica-se um filtro de coerência rítmica que remove pulsos intrusos — aqueles que quebram o padrão de intervalos regulares esperado em uma estridulação de grilo.

**Algoritmo:**

1. Para cada chirp, calcular todos os IPIs internos
2. Calcular a mediana dos IPIs:  $IPI_{med}$
3. Para cada pulso no chirp:  
Se  $|IPI_i - IPI_{med}| > \text{tolerância} \times IPI_{med}$  (tolerância=0.30):  
→ Remover o pulso (ritmicamente incoerente)
4. Re-validar contagem mínima de pulsos

**Justificativa biológica:** A estridulação dos Gryllidae é produzida por um gerador central de padrões (CPG — Central Pattern Generator) neuromotor que produz intervalos altamente regulares. A variabilidade natural do IPI em uma sequência legítima raramente excede  $\pm 30\%$  da mediana. Pulsos que violam esta regularidade são quase certamente originários de um segundo indivíduo (overlapping) ou de artefato ambiental.

## 5.6. Ciclo de Feedback do Aprendizado Ativo

O aprendizado ativo do Crinômetro segue o paradigma de **pool-based active learning** com feedback humano incremental:

**Passo 1 — Detecção Inicial:** O pipeline DSP detecta todos os pulsos candidatos usando apenas heurísticas paramétricas (threshold, morfologia, banda espectral).

**Passo 2 — Classificação Automática (se modelo existir):** O PulseLearner aplica o GMM e/ou classificador supervisionado para filtrar e classificar os pulsos.

**Passo 3 — Revisão Humana:** O pesquisador inspeciona visualmente os marcadores de pulso no espectrograma e oscilograma. Pulsos incorretamente incluídos são removidos (clique direito); pulsos não detectados são adicionados manualmente (clique esquerdo).

**Passo 4 — Salvamento de Correções:** Ao clicar em "Salvar Correções", o sistema:

- a) Extrai features de todos os pulsos validados → labels positivas (1)
- b) Extrai features de todos os pulsos removidos → labels negativas (0)
- c) Minera negativos adicionais: pulsos do envelope em regiões de silêncio, picos de baixa amplitude distantes dos pulsos validados
- d) Induz regras de poda contrastivas (Hard Negatives)
- e) Acumula exemplos no dataset histórico (até 5000 amostras)

- f) Re-treina o classificador com o dataset atualizado
- g) Serializa modelo + dataset via pickle em `modelo_treinado.pkl`

**Passo 5 — Adaptação Paramétrica:** Opcionalmente, o sistema ajusta automaticamente os parâmetros de proeminência e largura do pipeline DSP com base nas estatísticas dos pulsos validados pelo pesquisador, reduzindo a necessidade de correções futuras.

**Persistência e Transferência:** O modelo treinado é salvo em `modelo_treinado.pkl` e recarregado em sessões subsequentes. Pode ser exportado/importado entre pesquisadores via "Exportar/Carregar Treinamento (.pkl)".

## 6. GLOSSÁRIO METODOLÓGICO PARA DEFESA ACADÊMICA

### 6.1. Seção "Materiais e Métodos" — Modelo de Redação

A seguir, apresenta-se uma formulação no estilo "Materiais e Métodos" de artigo científico, adequada para inclusão direta em dissertações, teses e publicações:

*"Os arquivos de áudio no formato WAV (44.1 kHz, 16 bits) foram processados pelo software Crinômetro (v4.3.2). O sinal bruto foi condicionado pela remoção do offset DC seguida de filtragem passa-altas Butterworth de 2ª ordem ( $f_c = 50$  Hz) para eliminação de ruído infrassônico. A banda de estridulação foi isolada por um filtro Butterworth passa-faixa IIR de 4ª ordem com frequências de corte em 3200 Hz e 6000 Hz, ambos implementados na forma SOS (Second-Order Sections) para estabilidade numérica (Oppenheim & Willsky, 2014).*

*O envelope de amplitude foi extraído pela Transformada de Hilbert (Hilbert, 1912; Boashash, 1992) seguida de suavização por convolução com janela de Hanning de 2 ms. A detecção de pulsos utilizou busca de picos com threshold adaptativo baseado no 25º percentil da distribuição do envelope multiplicado por fator 2.5, validação morfológica (duração entre 3 e 50 ms), e rejeição de banda estreita ( $\pm 300$  Hz da frequência portadora modal).*

*O espectrograma foi computado por STFT (Short-Time Fourier Transform) com janela de Hann de 1024 amostras e sobreposição de 75%, resultando em resolução espectral de ~43 Hz e resolução temporal de ~5.8 ms. A frequência portadora foi refinada por interpolação parabólica sub-bin de Smith (1987) aplicada quadro a quadro.*

*A segregação acústica de indivíduos focais vs. coro distante empregou um Modelo de Mistura de Gaussianas (GMM) bimodal (Dempster et al., 1977) no espaço log-amplitude  $\times$  centroide espectral, complementado por um classificador HistGradientBoosting (Ke et al., 2017) treinado incrementalmente por aprendizado ativo com correções do pesquisador. O vetor de 20 características por pulso incluiu métricas temporais (duração, tempo de ataque 10-90%, fator de crista), espectrais (centroide, roll-off 85%, HNR) e contextuais (energia multiescala, prior focal do GMM).*

*O diagnóstico rítmico (aceleração/desaceleração) baseou-se em regressão linear dos ICIs ao longo do tempo, com significância estatística avaliada pela estatística  $t$  de Student ( $\alpha = 0.05$ ) e limiar de relevância clínica de  $|\beta| > 0.15$  ms/s. A estimativa de temperatura foi calculada pela Lei de Dolbear simplificada ( $T^{\circ}\text{C} = (R_{\text{min}} - 40)/4 + 10$ ; Dolbear, 1897)."*

### 6.2. Tabela Sintética: Conceito → Implementação → Localização

| Conceito Físico / Biológico       | Implementação Matemática                                          | Arquivo / Método               |
|-----------------------------------|-------------------------------------------------------------------|--------------------------------|
| Estridulação por fricção tegmenal | Sinal oscilatório quase-periódico na banda 3–8 kHz                | Entrada WAV bruta              |
| Frequência portadora modal        | Modo do histograma espectral (50 Hz bins) com refinamento         | analyze.py → analyze()         |
| Pulso individual (segmento)       | Segmento do envelope acima do threshold com duração definida      | analyze.py → find_peaks()      |
| Chilreio (chirp = trem de pulso)  | Grupo sequencial com IPI $\in [\text{gap\_min}, \text{gap\_max}]$ | analyzer.py → regroup_chirps() |

| Conceito Físico / Biológico | Implementação Matemática                                   | Arquivo / Método                     |
|-----------------------------|------------------------------------------------------------|--------------------------------------|
| Envelope de amplitude       | Módulo do sinal analítico via Transformada de Hilbert      | scipy.signal.hilbert()               |
| Espectrograma               | STFT com janela Hann 1024, overlap 75%, potência espectral | scipy.signal.spectrogram()           |
| Filtragem de banda          | Butterworth IIR 4ª ordem, forma SOS                        | scipy.signal.butter() + sosfilt()    |
| Separação focal/coro        | GMM bimodal + HistGradientBoosting supervisionada          | learn.py → PulseLearner              |
| Coerência rítmica           | Rejeição de pulsos com $ IPI - mediana  > 30\%$            | analyzer.py → regroup_chirps()       |
| Taxa de estridulação        | $N\_chirps / T\_total \times 60$ (chirps/min)              | analyze() métricas                   |
| Diagnóstico rítmico         | Regressão linear ICI(t), teste t de Student                | report_generator.py                  |
| Estimativa de temperatura   | Lei de Dolbear: $T^{\circ}C = (R\_min - 40)/4 + 10$        | analyze() métricas                   |
| Aprendizado ativo           | Pool-based AL com feedback humano incremental              | learn.py → update_from_corrections() |
| Poda contrastiva            | Regras induzidas por separação perfeita de features        | features.py → induce_pruning_rules() |

**Fim da Documentação Técnica.**

Documento gerado automaticamente em 18/09/2026 às 07:04 pelo Crinômetro — Documentador Científico.

# CRINÔMETRO

Documentação Técnica, Teórica e Metodológica

Análise de Processamento Digital de Sinais (DSP), Bioacústica Computacional,  
Aprendizado de Máquina e Métricas Fisiológicas da Estridulação de Gryllidae

**Versão do Software:** v4.3.2

**Data de Geração:** 18/09/2026 às 07:04

**Objetivo:** Servir como base formal para defesa acadêmica e redação científica, documentando exhaustivamente cada cálculo, decisão algorítmica e transformação de dados implementada no programa.

# SUMÁRIO

1. Arquitetura Geral e Pipeline de Dados (Dataflow)
2. Processamento Digital de Sinais (DSP): Teoria, Cálculo e Implementação
  - 2.1. Pré-Processamento e Condicionamento do Sinal
  - 2.2. Filtragem Passa-Faixa (Bandpass Filter)
  - 2.3. Transformada de Fourier e Espectrograma (STFT)
  - 2.4. Refinamento Sub-bin Parabólico de Frequência
  - 2.5. Densidade Espectral de Potência (PSD)
3. Detecção e Segmentação Bioacústica
  - 3.1. Extração de Envelope Temporal
  - 3.2. Algoritmo de Segmentação e Thresholding
  - 3.3. Agrupamento Hierárquico de Chirpeiros
  - 3.4. Tratamento de Ruídos e Falsos Positivos
4. Cálculo de Métricas Biométricas e Modelagem Fisiológica
  - 4.1. Métricas Temporais de Estridulação
  - 4.2. Diagnóstico Rítmico (Aceleração vs. Desaceleração)
  - 4.3. Correlação Termo-Acústica (Lei de Dolbear)
5. Módulo de IA e Aprendizado Ativo
  - 5.1. Vetor de Características (Feature Engineering)
  - 5.2. Separação Não-Supervisionada (GMM Bimodal)
  - 5.3. Classificador Supervisionado (HistGradientBoosting)
  - 5.4. Mineração de Negativos Difíceis (Hard Negative Mining)
  - 5.5. Filtro de Coerência Rítmica
  - 5.6. Ciclo de Feedback do Aprendizado Ativo
6. Glossário Metodológico para Defesa Acadêmica

# 1. ARQUITETURA GERAL E PIPELINE DE DADOS (DATAFLOW)

---

## 1.1. Ciclo de Vida do Sinal de Áudio

O Crinômetro implementa um pipeline sequencial de processamento que transforma uma gravação bruta em formato WAV em um conjunto estruturado de métricas bioacústicas e visualizações interativas. O ciclo de vida completo é:






Figura 1: Diagrama de fluxo do pipeline completo de processamento do Crinômetro.

## 1.2. Organização Modular e Desacoplamento

A arquitetura do Crinômetro separa rigorosamente a camada de interface gráfica (GUI) da camada de processamento matemático. Esta decisão atende a três requisitos fundamentais: (a) permitir que operações de DSP pesadas executem em threads secundárias sem congelar a interface; (b) facilitar testes unitários do core sem dependência do Qt; e (c) possibilitar reutilização do motor analítico em contextos não-interativos (scripts de lote, pipelines acadêmicos).

| Módulo                    | Arquivo                   | Responsabilidade                                                                                        |
|---------------------------|---------------------------|---------------------------------------------------------------------------------------------------------|
| CricketAnalyzer           | core/analyzer.py          | Pipeline DSP completo: filtragem, espectrograma, detecção de pulsos, agrupamento de chlíreios, métricas |
| PulseLearner              | core/learner.py           | ML Active Learning: extração de features, GMM, classificação supervisionada, poda contrastiva           |
| HighPerfLineEngine        | core/engines.py           | Renderização adaptativa LOD de formas de onda com decimação min-max                                     |
| HighPerfSpectrogramEngine | core/engines.py           | Renderização adaptativa de espectrogramas com cache de tiles e stride slicing                           |
| HighPerfFreqEngine        | core/engines.py           | Renderização adaptativa de scatter plots de frequência dominante                                        |
| GenericWorker             | core/worker.py            | Wrapper QThread com cancelamento cooperativo e sinalização typed                                        |
| MainWindow                | ui/main_window.py         | Orquestrador central: UI, estado, navegação, edição interativa, playback                                |
| PlotPanel                 | ui/panels.py              | Card de gráfico Matplotlib com tema, drag-drop, toolbar e tooltips                                      |
| report_generator          | utils/report_generator.py | Geração de relatórios PDF acadêmicos via ReportLab                                                      |

O desacoplamento é mediado pelo padrão de **worker assíncrono**: a `MainWindow` instancia um `GenericWorker(QThread)` que executa `CricketAnalyzer.analyze()` em uma thread secundária. Ao concluir, o resultado é emitido via sinal Qt (`finished_signal`) e recebido pelo slot da `MainWindow` na thread principal, que então atualiza a GUI. Este mecanismo garante que operações de FFT, Hilbert e classificação ML nunca bloqueiem o event loop do Qt.

## 2. PROCESSAMENTO DIGITAL DE SINAIS (DSP)

### 2.1. Pré-Processamento e Condicionamento do Sinal

Antes da análise bioacústica propriamente dita, o sinal bruto passa por três etapas de condicionamento que removem artefatos comuns em gravações de campo:

#### *Etapa 1: Leitura e Normalização*

O arquivo WAV é lido via `scipy.io.wavfile.read()`. Se o arquivo for estéreo (2 canais), os canais são colapsados para mono pela média aritmética: `data = raw.mean(axis=1)`. A amplitude é normalizada ao intervalo  $[-1.0, +1.0]$  dividindo pelo valor máximo absoluto do tipo de dado (32768 para int16, 2147483648 para int32). O resultado é convertido para float32 para reduzir em 50% o consumo de memória em relação a float64.

#### *Etapa 2: Remoção do Offset DC*

A média aritmética do sinal é subtraída de todas as amostras: `data = data - np.mean(data)`. Isto elimina qualquer componente de corrente contínua (DC offset) que possa estar presente devido a imperfeições no circuito de gravação ou calibração do microfone. Um offset DC não removido introduziria um pico espúrio em 0 Hz no espectro, distorcendo a detecção de frequência portadora.

#### *Etapa 3: Filtro Passa-Altas Anti-Vento (50 Hz)*

Um filtro Butterworth IIR de 2ª ordem com frequência de corte em 50 Hz é aplicado para atenuar ruídos de vento, vibrações mecânicas do suporte do microfone e interferência eletromagnética de rede elétrica (hum de 50/60 Hz). A topologia Butterworth foi escolhida por sua resposta em magnitude maximamente plana na banda passante, evitando ripple que poderia distorcer a envoltória temporal dos pulsos.

A implementação utiliza a forma SOS (Second-Order Sections) ao invés da forma de função de transferência (b, a) para garantir estabilidade numérica. A função de transferência de um filtro Butterworth passa-altas de 2ª ordem é:

$$H(s) = s^2 / (s^2 + \sqrt{2} \cdot \omega_c \cdot s + \omega_c^2) \text{ onde } \omega_c = 2\pi \times 50 \text{ Hz}$$

### 2.2. Filtragem Passa-Faixa (Bandpass Filter)

A etapa central de isolamento do sinal de estridulação utiliza um filtro Butterworth IIR passa-faixa de **4ª ordem** (cascata de 2 seções de 2ª ordem) com frequências de corte configuráveis. Os valores padrão —  **$f_{\text{low}} = 3200 \text{ Hz}$  e  $f_{\text{high}} = 6000 \text{ Hz}$**  — foram calibrados empiricamente para capturar a faixa de estridulação da maioria das espécies de Gryllidae comuns em gravações de campo no Brasil (gêneros *Gryllus*, *Anurogryllus*, *Oecanthus*).

#### *Justificativa da Topologia Butterworth*

A resposta em magnitude do filtro Butterworth de ordem N satisfaz:

$$|H(j\omega)|^2 = 1 / [1 + (\omega/\omega_c)^{(2N)}]$$

Três propriedades tornam esta topologia ideal para bioacústica de insetos: (1) **Resposta maximamente plana** na banda passante — não introduz ripple que distorceria a envoltória temporal dos pulsos. Filtros Chebyshev tipo I, por exemplo, apresentam oscilações na banda passante que poderiam gerar falsos

picos no envelope. (2) **Atenuação monotônica** na banda de rejeição — garante supressão progressiva de frequências fora da faixa de interesse sem side-lobes. (3) **Fase suavemente variável** — embora não seja linear, a fase do Butterworth é mais suave que a do Chebyshev, preservando melhor a forma temporal dos pulsos de estridulação.

A **4ª ordem** (atenuação de 80 dB/década = 24 dB/oitava por polo) fornece uma rejeição suficiente para separar o canto do grilo focal de fontes de banda larga (tráfego, vento, outros artrópodes) sem o custo computacional de ordens superiores. Ordens acima de 6 tendem a causar instabilidade numérica na forma (b, a), embora a implementação SOS mitigue este risco.

### Implementação

```
sos = scipy.signal.butter(4, [f_low/(sr/2), f_high/(sr/2)], btype='band',
output='sos')
data_filtered = scipy.signal.sosfilt(sos, data).astype(np.float32)
```

A normalização das frequências de corte pelo Nyquist ( $sr/2$ ) é necessária porque a função `butter()` espera frequências normalizadas no intervalo (0, 1). Valores fora de (0.001, 0.999) são clampeados para evitar instabilidade.

## 2.3. Transformada de Fourier de Curto Tempo (STFT) e Espectrograma

O espectrograma do Crinômetro é calculado via STFT usando a função `scipy.signal.spectrogram()` com os seguintes parâmetros:

| Parâmetro             | Valor Padrão                | Significado Físico                                           |
|-----------------------|-----------------------------|--------------------------------------------------------------|
| <code>nperseg</code>  | 1024 amostras               | Tamanho da janela de análise ( $\approx 23.2$ ms a 44.1 kHz) |
| <code>window</code>   | Hann (cosseno elevado)      | Função de janelamento para redução de vazamento espectral    |
| <code>noverlap</code> | 768 amostras (75%)          | Sobreposição entre janelas consecutivas                      |
| <code>hop_size</code> | 256 amostras (= 1024 - 768) | Deslocamento temporal entre quadros ( $\approx 5.8$ ms)      |
| <code>scaling</code>  | 'spectrum'                  | Retorna potência por bin de frequência (não por Hz)          |

### Resoluções Resultantes

O Princípio da Incerteza de Heisenberg-Gabor estabelece que a resolução temporal ( $\Delta t$ ) e a resolução espectral ( $\Delta f$ ) de qualquer análise tempo-frequência são mutuamente exclusivas:

$$\Delta t \times \Delta f \geq 1 / (4\pi)$$

Para os parâmetros escolhidos ( $sr = 44100$  Hz,  $nperseg = 1024$ ):

- **Resolução em frequência:**  $\Delta f = sr / nperseg = 44100 / 1024 \approx 43.07$  Hz
- **Resolução temporal:**  $\Delta t = hop\_size / sr = 256 / 44100 \approx 5.8$  ms

Esta parametrização privilegia a **resolução temporal** em detrimento da espectral. A escolha é fundamentada na natureza do sinal de estridulação: cada pulso individual de um grilo dura tipicamente entre 3 e 30 ms, exigindo resolução temporal sub-milissegundos para segmentação precisa. A resolução espectral de  $\sim 43$  Hz é suficiente para distinguir a frequência portadora (tipicamente entre 3 e 8 kHz) e seus harmônicos mais proeminentes.

## Conversão para Decibéis

A matriz de potência  $S_{xx}$  é convertida para escala logarítmica:

$$S_{dB}(f, t) = 10 \cdot \log_{10}(S_{xx}(f, t) + 10^{-10})$$

O epsilon aditivo ( $10^{-10}$ , equivalente a -100 dB) previne o logaritmo de zero em regiões de silêncio absoluto. A matriz resultante é convertida para `float32` para economia de memória.

## 2.4. Refinamento Sub-bin Parabólico de Frequência

A resolução espectral do espectrograma (~43 Hz) é insuficiente para rastreamento preciso da frequência portadora do grilo, cuja variação natural pode ser de apenas  $\pm 10$ -20 Hz. Para superar esta limitação, o Crinômetro aplica **interpolação parabólica sub-bin** a cada coluna temporal do espectrograma.

Para cada instante  $t$ , identifica-se o bin de frequência  $k$  com maior potência. Usando os valores de potência logarítmica dos bins adjacentes ( $k-1$ ,  $k$ ,  $k+1$ ), calcula-se o offset fracionário  $p$  do pico verdadeiro:

$$p = 0.5 \times (\alpha - \gamma) / (\alpha - 2\beta + \gamma)$$

$$\text{onde } \alpha = S_{dB}[k-1], \beta = S_{dB}[k], \gamma = S_{dB}[k+1]$$

A frequência dominante refinada é então:

$$f_{\text{peak}}(t) = f[k] + p \times \Delta f$$

Este método reduz o erro de estimação de frequência de  $\pm \Delta f/2$  ( $\approx 21.5$  Hz) para aproximadamente  $\pm \Delta f/10$  ( $\approx 4.3$  Hz), oferecendo precisão sub-bin sem o custo computacional de zero-padding ou janelas maiores.

## 3. DETECÇÃO E SEGMENTAÇÃO BIOACÚSTICA

### 3.1. Extração de Envelope Temporal

O envelope de amplitude é a curva que delineia os picos instantâneos do sinal filtrado, eliminando as oscilações rápidas da frequência portadora e preservando apenas a modulação de amplitude (AM) que define a estrutura temporal dos pulsos. O Crinômetro utiliza a **Transformada de Hilbert** para esta finalidade.

#### Fundamento Matemático

Dado um sinal real  $x(t)$ , a Transformada de Hilbert produz o sinal analítico:

$$x_a(t) = x(t) + j \cdot H\{x(t)\}$$

onde  $H\{\cdot\}$  é o operador de Hilbert (rotação de fase de  $-90^\circ$  para frequências positivas e  $+90^\circ$  para negativas). O envelope instantâneo é o módulo do sinal analítico:

$$A(t) = |x_a(t)| = \sqrt{[x(t)]^2 + [H\{x(t)\}]^2}$$

#### Implementação e Suavização

```
analytic = scipy.signal.hilbert(data_filtered)
envelope = np.abs(analytic).astype(np.float32)
```

O envelope bruto apresenta ripple residual da portadora. Para eliminar estas flutuações, aplica-se uma **suavização por janela de Hanning** via convolução:

```
win = np.hanning(smooth_samples)
win /= win.sum()
envelope_smooth = np.convolve(envelope, win, mode='same')
```

O tamanho da janela de suavização (padrão: 2 ms, configurável pelo pesquisador) controla o trade-off entre resolução temporal e supressão de ripple. Janelas maiores produzem envelopes mais suaves mas podem fundir pulsos adjacentes muito próximos; janelas menores preservam detalhes mas podem gerar detecções espúrias.

#### Normalização Robusta

O envelope é normalizado pelo percentil 99.85 da distribuição de amplitude (ao invés do máximo absoluto). Esta abordagem é robusta a cliques, estalos e artefatos transientes que poderiam comprimir toda a faixa dinâmica se o máximo absoluto fosse utilizado. A constante 99.85 foi calibrada empiricamente para rejeitar os 0.15% mais extremos das amostras sem afetar os pulsos legítimos de estridulação.

### 3.2. Algoritmo de Detecção de Pulsos e Thresholding

A detecção de pulsos opera sobre o envelope suavizado e normalizado. O processo envolve três fases: (1) estimação do limiar adaptativo, (2) detecção de picos, e (3) validação morfológica.

#### Fase 1: Limiar Adaptativo

O limiar de detecção é calculado adaptativamente a partir da distribuição estatística do envelope:

$$\text{threshold} = \max(\text{amp\_min} \times \text{noise\_floor}, P_{25} \times 2.5)$$

onde **amp\_min** é o limiar mínimo configurável (padrão: 0.08), **noise\_floor** é a mediana do envelope nas regiões de silêncio, e **P<sub>25</sub>** é o 25º percentil da distribuição do envelope. O fator multiplicativo de 2.5 foi determinado empiricamente para maximizar a taxa de detecção verdadeira (recall) mantendo a taxa de falsos positivos abaixo de 5% em gravações com SNR  $\geq 10$  dB.

### **Fase 2: Detecção de Picos**

A detecção utiliza `scipy.signal.find_peaks()` com os seguintes critérios:

- **height**: threshold calculado na Fase 1
- **prominence**: proeminência mínima configurável (garante que o pico se destaque significativamente de seus vizinhos)
- **width**: largura do pico a 50% da altura entre `width_min` e `width_max` (em amostras), equivalente à duração do pulso entre `dur_min` e `dur_max` (em ms)
- **distance**: distância mínima entre picos consecutivos ( $= \text{gap\_min} \times \text{sr}$ , prevenindo dupla detecção)

### **Fase 3: Validação Morfológica**

Cada pulso candidato é submetido a validação de duração:

- Duração calculada:  $d = \text{largura do pico a 50\% da altura (FWHM) via } \text{peak\_widths}()$
- Critério:  $\text{dur\_min (3 ms)} \leq d \leq \text{dur\_max (50 ms)}$
- Pulsos fora deste intervalo são rejeitados como artefatos (muito curtos = cliques; muito longos = sobreposição de múltiplos pulsos)

## **3.3. Identificação da Frequência Portadora e Filtragem Espectral**

Após a detecção de pulsos candidatos, o sistema identifica a **frequência portadora modal** — a frequência de estridulação dominante que caracteriza o indivíduo focal.

**Algoritmo:** Para cada pulso validado, extrai-se a frequência dominante do espectrograma no instante do pico (usando o refinamento sub-bin parabólico da Seção 2.4). Constrói-se um histograma ponderado dessas frequências com largura de bin de 50 Hz, e a moda do histograma é designada como a frequência portadora  $f_{\text{carrier}}$ .

Pulsos cuja frequência dominante difere da portadora em mais de  $\pm \text{freq\_tolerance}$  (padrão: 300 Hz) são rejeitados como provenientes de outras fontes acústicas (outros grilos, cigarras, ruído ambiental). Esta é a **Filtragem de Rejeição de Banda Estreita** introduzida na v4.3.0.

## **3.4. Agrupamento Hierárquico em Chilreios (Chirps)**

Os pulsos validados e filtrados espectralmente são agrupados em **chilreios** (chirps) — sequências rítmicas de pulsos produzidas por um único ciclo de fechamento tegminal. O agrupamento segue um algoritmo sequencial com múltiplas camadas de validação:

**Camada 1 — Agrupamento Temporal:** Pulsos consecutivos são agrupados no mesmo chilreio se o intervalo inter-pulso (IPI) estiver dentro do intervalo  $[\text{gap\_min}, \text{gap\_max}]$  (padrão: [20 ms, 40 ms]). Um IPI menor que `gap_min` sugere colisão de dois pulsos sobrepostos; um IPI maior que `gap_max` indica o fim do chilreio.

**Camada 2 — Coerência de Amplitude:** Dentro de cada chilreio candidato, a amplitude dos pulsos é verificada: a razão entre o pulso mais fraco e a mediana não deve exceder um fator de 1.65×. Isto rejeita

intrusões de pulsos distantes (coro de fundo) que coincidem temporalmente mas apresentam amplitude discrepante.

**Camada 3 — Detecção de Colisão:** Se dois pulsos estão separados por menos de  $0.8 \times \text{gap\_min}$ , é provável que sejam pulsos sobrepostos de dois indivíduos diferentes. O sistema retém o pulso de maior amplitude e descarta o mais fraco.

**Camada 4 — Portão ICI (Inter-Chirp Interval Gate):** Após o agrupamento inicial, aplica-se um filtro de período refratário fisiológico. Para cada par de chilreios consecutivos, se o intervalo inter-chilreio (ICI) for inferior a 70% da mediana dos ICIs ( $\text{ICI}_{\text{gate}} = 0.70 \times \text{ICI}_{\text{mediana}}$ ), os dois chilreios são fundidos em um único (o intervalo era curto demais para ser uma pausa fisiológica real).

**Camada 5 — Validação de Contagem Mínima:** Chilreios com menos de  $\text{min\_p}$  pulsos (padrão: 3) são descartados, pois não constituem uma sequência rítmica suficiente para classificação bioacústica confiável.

### 3.5. Tratamento de Ruídos e Falsos Positivos

O sistema emprega múltiplas estratégias hierárquicas para discriminar sinal de ruído:

- **Filtragem passa-faixa:** Remove ruído fora da banda de estridulação
- **Threshold adaptativo:** Se ajusta ao nível de ruído específico da gravação
- **Validação morfológica:** Rejeita pulsos com duração ou largura fora do esperado
- **Tolerância espectral:** Rejeita pulsos com frequência fora da portadora  $\pm 300$  Hz
- **Coerência de amplitude:** Remove intrusos com amplitude incompatível
- **ICI Gate:** Rejeita detecções no período refratário fisiológico
- **Classificador ML (opcional):** Discriminação supervisionada baseada em 20 features acústicas

**Diferenciação de pausa fisiológica vs. ruído transitório:** Uma pausa fisiológica genuína (o grilo interrompeu temporariamente a estridulação) é caracterizada por: (a) ICI significativamente maior que a mediana ( $> 3\times$ ), (b) ausência de pulsos espúrios durante a pausa, e (c) retomada da cadência com IPI consistente. O sistema identifica estas pausas e as exclui dos cálculos de taxa e cadência para evitar distorção das métricas.

## 4. CÁLCULO DE MÉTRICAS BIOMÉTRICAS E MODELAGEM FISIOLÓGICA

### 4.1. Métricas Temporais de Estridulação

As métricas bioacústicas calculadas pelo Crinômetro são formalmente definidas a seguir. Todas as equações são aplicadas sobre os chilreios validados pelo pipeline completo.

| Métrica                    | Símbolo       | Fórmula                                          | Unidade    |
|----------------------------|---------------|--------------------------------------------------|------------|
| Total de Chilreios         | N_c           | Contagem de chirps validados                     | —          |
| Total de Pulsos            | N_p           | $\sum  chirp\_i $ para todos os chirps           | —          |
| Taxa de Chilreios          | R_c           | $N\_c / T\_total$                                | chirps/s   |
| Cadência                   | R_min         | $R\_c \times 60$                                 | chirps/min |
| ICI Médio                  | $\mu\_ICI$    | $(1/n)\sum (onset[i+1] - offset[i])$             | ms         |
| ICI Desvio Padrão          | $\sigma\_ICI$ | $std(ICIs)$                                      | ms         |
| IPI Médio                  | $\mu\_IPI$    | $(1/m)\sum (onset[j+1] - offset[j])$ intra-chirp | ms         |
| IPI Desvio Padrão          | $\sigma\_IPI$ | $std(IPIs)$                                      | ms         |
| Duração Média do Pulso     | $\mu\_d\_p$   | $(1/N\_p)\sum (offset[k] - onset[k])$            | ms         |
| Duração Média do Chilreio  | $\mu\_d\_c$   | $(1/N\_c)\sum (offset\_last - onset\_first)$     | ms         |
| Pulsos por Chilreio (Moda) | Mo_ppc        | $mode(\{  chirp\_i  \})$                         | —          |
| Frequência Portadora       | f_carrier     | moda do histograma espectral (50 Hz bins)        | Hz         |

O **Intervalo Inter-Chilreio (ICI)** é medido do offset do último pulso de um chilreio ao onset do primeiro pulso do chilreio seguinte. O **Intervalo Inter-Pulso (IPI)** é medido analogamente dentro de um mesmo chilreio. Esta definição (offset-to-onset) ao invés de (onset-to-onset) é mais apropriada bioacusticamente pois mede o período de silêncio real entre eventos, e não o período do ciclo que inclui a duração do evento anterior.

### 4.2. Diagnóstico Rítmico (Aceleração vs. Desaceleração)

O diagnóstico rítmico avalia se o grilo está acelerando, desacelerando ou mantendo cadência estável ao longo da gravação. O modelo empregado é uma **regressão linear simples** dos ICIs ao longo do tempo:

$$ICI(t) = \beta_0 + \beta_1 \cdot t + \epsilon$$

onde  $\beta_1$  (slope) é a taxa de variação do ICI em ms/s. O ajuste é realizado via `numpy.polyfit(timestamps, icis_ms, deg=1)`.

**Critérios de Diagnóstico:**

- **Aceleração:**  $\beta_1 < -0.15$  ms/s E p-valor  $< 0.05$   
(ICIs ficando menores → chirps mais frequentes → acelerando)
- **Desaceleração:**  $\beta_1 > +0.15$  ms/s E p-valor  $< 0.05$

(ICIs ficando maiores → chirps menos frequentes → desacelerando)

• **Estável:**  $|\beta| \leq 0.15 \text{ ms/s}$  OU  $p\text{-valor} \geq 0.05$

(Sem tendência significativa)

A significância estatística é testada via **coeficiente de correlação de Pearson** convertido em estatística  $t$  de Student:

$$t = r \times \sqrt{(n-2) / (1 - r^2)} \rightarrow p = 2 \times [1 - \text{CDF}_t(|t|, df=n-2)]$$

**Filtragem de pausas fisiológicas:** ICIs maiores que 3× a mediana são excluídos da regressão, pois representam interrupções do comportamento de estridulação (o grilo parou de cantar brevemente) e não variações rítmicas genuínas.

### 4.3. Correlação Termo-Acústica (Lei de Dolbear)

A Lei de Dolbear (1897) descreve uma relação empírica aproximadamente linear entre a taxa de estridulação de grilos e a temperatura ambiente. A formulação implementada no Crinômetro é baseada na versão simplificada para grilo-de-campo (*Gryllus*):

$$T(^{\circ}\text{C}) = (R_{\min} - 40) / 4 + 10$$

onde  $R_{\min}$  é a cadência de chilreios por minuto. Esta fórmula é derivada da Lei de Dolbear original para *Oecanthus fultoni* ( $T^{\circ}\text{F} = 40 + n/4$ , onde  $n$  = número de chirps em 13 segundos), adaptada e convertida para Celsius.

**Limitações importantes:** A estimativa de temperatura é apresentada como valor informativo e indicativo, não como medição precisa. A relação é espécie-específica — grilos de espécies diferentes (e.g., *Gryllus* vs. *Oecanthus*) têm coeficientes distintos. Além disso, fatores como estresse, competição intraespecífica e estado nutricional podem modular a taxa independentemente da temperatura.

## 5. MÓDULO DE IA E APRENDIZADO ATIVO

O módulo de inteligência artificial do Crinômetro (PulseLearner) implementa um sistema híbrido de classificação que combina (a) clustering não-supervisionado via GMM bimodal, (b) classificação supervisionada via gradient boosting, e (c) aprendizado ativo onde o pesquisador refina progressivamente o modelo corrigindo detecções individuais.

### 5.1. Vetor de Características (Feature Engineering)

Para cada pulso candidato, o sistema extrai um **vetor de 20 características** bioacústicas calculadas em uma janela de  $\pm 30$  ms centrada no pico do envelope. Estas características foram selecionadas para serem **invariantes a ganho** (normalizadas por amplitude local) e **fisicamente interpretáveis**:

| #  | Feature              | Fórmula / Método                                              | Significado Bioacústico                              |
|----|----------------------|---------------------------------------------------------------|------------------------------------------------------|
| 1  | peak_amp_rel         | $A_{\text{peak}} / \text{mediana}(A_{\text{local}})$          | Amplitude relativa: distingue focal de coro distante |
| 2  | peak_width_s         | FWHM a 50% da altura                                          | Duração do pulso: espécie-específica                 |
| 3  | peak_width_75_s      | Largura a 75% da altura                                       | Forma do pico: pulsos focais são mais estreitos      |
| 4  | local_snr_db         | $20 \cdot \log_{10}(A_{\text{peak}} / \sigma_{\text{local}})$ | Razão sinal-ruído local                              |
| 5  | energy_rel           | $E_{\text{janela}} / A_{\text{peak}}^2$                       | Energia normalizada do pulso                         |
| 6  | std_amp_rel          | $\sigma_{\text{local}} / A_{\text{peak}}$                     | Variabilidade de amplitude local                     |
| 7  | prominence_ratio     | $(A_{\text{peak}} - A_{\text{vale}}) / A_{\text{peak}}$       | Proeminência relativa do pico                        |
| 8  | peak_sharpness_rel   | $d^2\text{env}/dt^2$ no pico (normalizado)                    | Agudeza do pico (2ª derivada)                        |
| 9  | crest_factor         | $A_{\text{peak}} / \text{RMS}_{\text{local}}$                 | Fator de crista: impulsividade do sinal              |
| 10 | skewness_local       | $(\mu_{\text{esq}} - \mu_{\text{dir}}) / A_{\text{peak}}$     | Assimetria temporal do envelope                      |
| 11 | local_density_rel    | $E_{\pm 10\text{ms}} / E_{\pm 30\text{ms}}$                   | Concentração de energia temporal                     |
| 12 | autocorr_1ms         | $r(\tau=1\text{ms})$ normalizada                              | Periodicidade a curto prazo                          |
| 13 | band_energy_ratio    | $E_{\pm 10\text{ms}} / E_{\pm 30\text{ms}}$                   | Foco energético vs contexto                          |
| 14 | rise_slope_rel       | $\Delta\text{env}/\Delta t$ (vale→pico)                       | Velocidade de ataque do pulso                        |
| 15 | spectral_centroid    | $\Sigma(f \cdot  X ) / \Sigma X $                             | Centro de massa espectral (Hz)                       |
| 16 | spectral_rolloff_85  | f tal que $\text{CDF}( X ^2)=0.85$                            | Decaimento espectral a 85%                           |
| 17 | attack_time_10_90_ms | $t(90\%) - t(10\%)$ interpolado                               | Tempo de subida 10-90% (ms)                          |
| 18 | local_hnr_db         | $E_{\text{harmônica}} / E_{\text{ruído}} (\pm 150\text{Hz})$  | Razão harmônico-ruído local                          |
| 19 | multiscale_energy    | $E_{\pm 10\text{ms}} / E_{\pm 40\text{ms}}$                   | Razão energia multiescala                            |
| 20 | prior_p_focal        | $P(\text{focal} \mid \text{GMM})$                             | Prior não-supervisionado do GMM                      |

### 5.2. Separação Não-Supervisionada (GMM Bimodal)

O módulo GMM (Gaussian Mixture Model) modela a distribuição das features de pulso como uma mistura de **duas gaussianas** representando dois clusters:

- **Cluster Focal:** Pulsos do grilo mais próximo (alta amplitude, centroide espectral consistente, alto HNR)
- **Cluster Coro/Ruído:** Pulsos distantes, ecos, ruído ambiental (baixa amplitude, centroide disperso, baixo HNR)

O GMM é ajustado em um espaço bidimensional de [log(amplitude), centroide\_espectral] padronizado (Z-score). A designação focal/coro é feita automaticamente: o cluster com maior média de amplitude + 0.5 × centroide é marcado como focal.

$$P(\text{focal} \mid x) = \pi_{\text{focal}} \cdot N(x \mid \mu_{\text{focal}}, \Sigma_{\text{focal}}) / \sum_k \pi_k \cdot N(x \mid \mu_k, \Sigma_k)$$

O `GaussianMixture` do `scikit-learn` é instanciado com `n_components=2`, `covariance_type='full'`, `n_init=5`. O uso de covariância 'full' permite clusters elipsoidais de orientação arbitrária, capturando correlações entre amplitude e frequência.

### 5.3. Classificador Supervisionado (HistGradientBoosting)

Quando o pesquisador fornece correções manuais, o sistema treina um classificador supervisionado que substitui (ou complementa) a classificação GMM.

#### *Classificador Primário: HistGradientBoostingClassifier*

- **max\_iter:** 200 iterações de boosting
- **max\_depth:** 3-4 (árvores rasas para evitar overfitting com poucos exemplos)
- **learning\_rate:** 0.1
- **l2\_regularization:** 2.0 (quando < 30 amostras) — regularização forte
- **class\_weight:** 'balanced' — compensa desbalanceamento entre classes
- **min\_samples\_leaf:** 5 — evita folhas com pouquíssimas amostras

O **HistGradientBoosting** foi escolhido por duas vantagens: (1) construção de histogramas de features é  $O(n)$  em vez de  $O(n \cdot \log n)$  como GBDT clássico, permitindo treinamento rápido durante a interação do pesquisador; (2) suporta nativamente valores faltantes (NaN) sem necessidade de imputação.

#### *Classificador de Fallback: RandomForestClassifier*

Se o HistGradientBoosting não estiver disponível (versões antigas do sklearn), o sistema utiliza um Random Forest com 500 estimadores, `max_depth=10`, `n_jobs=-1` (paralelismo total).

#### *Score Híbrido*

A decisão final combina a probabilidade do classificador supervisionado com o prior do GMM:

$$\text{Score} = 0.65 \times P(\text{válido} \mid \text{classificador}) + 0.35 \times P(\text{focal} \mid \text{GMM})$$

Um pulso é aceito se  $\text{Score} \geq \text{focal\_sensitivity}$  (padrão: 0.60). O peso maior no classificador (65%) reflete a maior confiabilidade das labels humanas em relação ao clustering não-supervisionado.

### 5.4. Mineração de Negativos Difíceis (Hard Negative Mining)

Quando o pesquisador remove manualmente pulsos falsos positivos (clikando em marcadores espúrios), o sistema analisa os vetores de features desses negativos explícitos e **induz regras de poda**

**contrastivas.**

**Algoritmo:** Para cada uma das 20 features, compara-se a distribuição dos positivos validados vs. negativos explícitos. Se uma feature  $f_i$  separa perfeitamente os dois grupos (i.e., nenhum overlap), uma regra é criada:

Se  $f_i < \text{threshold\_com\_margem\_30\%} \rightarrow \text{Rejeitar pulso}$

A margem de segurança de 30% previne rejeição de positivos borderline. Estas regras são aplicadas **antes** do classificador ML, funcionando como um filtro rápido  $O(1)$  por pulso.

## 5.5. Filtro de Coerência Rítmica $O(N)$

Após o agrupamento em chilreios, aplica-se um filtro de coerência rítmica que remove pulsos intrusos — aqueles que quebram o padrão de intervalos regulares esperado em uma estridulação de grilo.

**Algoritmo:**

1. Para cada chirp, calcular todos os IPIs internos
2. Calcular a mediana dos IPIs:  $IPI_{med}$
3. Para cada pulso no chirp:  
Se  $|IPI_i - IPI_{med}| > \text{tolerância} \times IPI_{med}$  (tolerância=0.30):  
→ Remover o pulso (ritmicamente incoerente)
4. Re-validar contagem mínima de pulsos

**Justificativa biológica:** A estridulação dos Gryllidae é produzida por um gerador central de padrões (CPG — Central Pattern Generator) neuromotor que produz intervalos altamente regulares. A variabilidade natural do IPI em uma sequência legítima raramente excede  $\pm 30\%$  da mediana. Pulsos que violam esta regularidade são quase certamente originários de um segundo indivíduo (overlapping) ou de artefato ambiental.

## 5.6. Ciclo de Feedback do Aprendizado Ativo

O aprendizado ativo do Crinômetro segue o paradigma de **pool-based active learning** com feedback humano incremental:

**Passo 1 — Detecção Inicial:** O pipeline DSP detecta todos os pulsos candidatos usando apenas heurísticas paramétricas (threshold, morfologia, banda espectral).

**Passo 2 — Classificação Automática (se modelo existir):** O PulseLearner aplica o GMM e/ou classificador supervisionado para filtrar e classificar os pulsos.

**Passo 3 — Revisão Humana:** O pesquisador inspeciona visualmente os marcadores de pulso no espectrograma e oscilograma. Pulsos incorretamente incluídos são removidos (clique direito); pulsos não detectados são adicionados manualmente (clique esquerdo).

**Passo 4 — Salvamento de Correções:** Ao clicar em "Salvar Correções", o sistema:

- a) Extrai features de todos os pulsos validados → labels positivas (1)
- b) Extrai features de todos os pulsos removidos → labels negativas (0)
- c) Minera negativos adicionais: pulsos do envelope em regiões de silêncio, picos de baixa amplitude distantes dos pulsos validados
- d) Induz regras de poda contrastivas (Hard Negatives)
- e) Acumula exemplos no dataset histórico (até 5000 amostras)

- f) Re-treina o classificador com o dataset atualizado
- g) Serializa modelo + dataset via pickle em `modelo_treinado.pkl`

**Passo 5 — Adaptação Paramétrica:** Opcionalmente, o sistema ajusta automaticamente os parâmetros de proeminência e largura do pipeline DSP com base nas estatísticas dos pulsos validados pelo pesquisador, reduzindo a necessidade de correções futuras.

**Persistência e Transferência:** O modelo treinado é salvo em `modelo_treinado.pkl` e recarregado em sessões subsequentes. Pode ser exportado/importado entre pesquisadores via "Exportar/Carregar Treinamento (.pkl)".

## 6. GLOSSÁRIO METODOLÓGICO PARA DEFESA ACADÊMICA

### 6.1. Seção "Materiais e Métodos" — Modelo de Redação

A seguir, apresenta-se uma formulação no estilo "Materiais e Métodos" de artigo científico, adequada para inclusão direta em dissertações, teses e publicações:

*"Os arquivos de áudio no formato WAV (44.1 kHz, 16 bits) foram processados pelo software Crinômetro (v4.3.2). O sinal bruto foi condicionado pela remoção do offset DC seguida de filtragem passa-altas Butterworth de 2ª ordem ( $f_c = 50$  Hz) para eliminação de ruído infrassônico. A banda de estridulação foi isolada por um filtro Butterworth passa-faixa IIR de 4ª ordem com frequências de corte em 3200 Hz e 6000 Hz, ambos implementados na forma SOS (Second-Order Sections) para estabilidade numérica (Oppenheim & Willsky, 2014).*

*O envelope de amplitude foi extraído pela Transformada de Hilbert (Hilbert, 1912; Boashash, 1992) seguida de suavização por convolução com janela de Hanning de 2 ms. A detecção de pulsos utilizou busca de picos com threshold adaptativo baseado no 25º percentil da distribuição do envelope multiplicado por fator 2.5, validação morfológica (duração entre 3 e 50 ms), e rejeição de banda estreita ( $\pm 300$  Hz da frequência portadora modal).*

*O espectrograma foi computado por STFT (Short-Time Fourier Transform) com janela de Hann de 1024 amostras e sobreposição de 75%, resultando em resolução espectral de ~43 Hz e resolução temporal de ~5.8 ms. A frequência portadora foi refinada por interpolação parabólica sub-bin de Smith (1987) aplicada quadro a quadro.*

*A segregação acústica de indivíduos focais vs. coro distante empregou um Modelo de Mistura de Gaussianas (GMM) bimodal (Dempster et al., 1977) no espaço log-amplitude  $\times$  centroide espectral, complementado por um classificador HistGradientBoosting (Ke et al., 2017) treinado incrementalmente por aprendizado ativo com correções do pesquisador. O vetor de 20 características por pulso incluiu métricas temporais (duração, tempo de ataque 10-90%, fator de crista), espectrais (centroide, roll-off 85%, HNR) e contextuais (energia multiescala, prior focal do GMM).*

*O diagnóstico rítmico (aceleração/desaceleração) baseou-se em regressão linear dos ICIs ao longo do tempo, com significância estatística avaliada pela estatística  $t$  de Student ( $\alpha = 0.05$ ) e limiar de relevância clínica de  $|\beta| > 0.15$  ms/s. A estimativa de temperatura foi calculada pela Lei de Dolbear simplificada ( $T^{\circ}\text{C} = (R_{\min} - 40)/4 + 10$ ; Dolbear, 1897)."*

### 6.2. Tabela Sintética: Conceito → Implementação → Localização

| Conceito Físico / Biológico       | Implementação Matemática                                          | Arquivo / Método               |
|-----------------------------------|-------------------------------------------------------------------|--------------------------------|
| Estridulação por fricção tegmenal | Sinal oscilatório quase-periódico na banda 3–8 kHz                | Entrada WAV bruta              |
| Frequência portadora modal        | Modo do histograma espectral (50 Hz bins) com refinamento         | analyze.py → analyze()         |
| Pulso individual (Segmento)       | Detecção do envelope acima do threshold com duração variável      | analyze.py → find_peaks()      |
| Chilreio (chirp = trem de pulso)  | Grupo sequencial com IPI $\in [\text{gap\_min}, \text{gap\_max}]$ | analyzer.py → regroup_chirps() |

| Conceito Físico / Biológico | Implementação Matemática                                   | Arquivo / Método                     |
|-----------------------------|------------------------------------------------------------|--------------------------------------|
| Envelope de amplitude       | Módulo do sinal analítico via Transformada de Hilbert      | scipy.signal.hilbert()               |
| Espectrograma               | STFT com janela Hann 1024, overlap 75%, potência espectral | scipy.signal.spectrogram()           |
| Filtragem de banda          | Butterworth IIR 4ª ordem, forma SOS                        | scipy.signal.butter() + sosfilt()    |
| Separação focal/correlação  | GMM bimodal + HistGradientBoosting supervisionada          | learn.py → PulseLearner              |
| Coerência rítmica           | Rejeição de pulsos com $ IPI - mediana  > 30\%$            | analyzer.py → regroup_chirps()       |
| Taxa de estridulação        | $N\_chirps / T\_total \times 60$ (chirps/min)              | analyze() métricas                   |
| Diagnóstico rítmico         | Regressão linear ICI(t), teste t de Student                | report_generator.py                  |
| Estimativa de temperatura   | Lei de Dolbear: $T^{\circ}C = (R\_min - 40)/4 + 10$        | analyze() métricas                   |
| Aprendizado ativo           | Pool-based AL com feedback humano incremental              | learn.py → update_from_corrections() |
| Poda contrastiva            | Regras induzidas por separação perfeita de features        | features.py → induce_pruning_rules() |

---

***Fim da Documentação Técnica.***

*Documento gerado automaticamente em 18/09/2026 às 07:04 pelo Crinômetro — Documentador Científico.*